



**Facultad de
Cs. de la Computación**

**BENEMÉRITA UNIVERSIDAD AUTÓNOMA DE
PUEBLA**

FACULTAD DE CIENCIAS DE LA COMPUTACIÓN

MINERIA DE DATOS

PRACTICA VI:

**AGRUPAMIENTO JERÁRQUICO POR EL
MÉTODO DE WARD**

Juárez González Berenice - 202042438
Viveros Santiago César Alberto - 201945254
Mora Martinez Christian - 201940541

Profesor TECUANHUEHUE VERA PEDRO

16 de mayo de 2024

Índice

1. Introducción	3
2. Descripción del algoritmo	4
2.1. Agrupación Jerárquica Aglomerativa	4
2.2. Agrupación Jerárquica Divisiva	5
2.3. Procedimiento	6
2.4. Medidas de Vinculación	6
2.5. Dendrograma	7
2.6. Líneas de corte	8
3. Metodología	9
3.1. Procedimiento	9
3.1.1. Etapa 1: Recopilación y preparación de datos	9
3.1.2. Etapa 2: Elección de variables	9
3.1.3. Etapa 3: Cálculo de la matriz de distancias	9
3.1.4. Etapa 4: Agrupamiento Jerárquico	9
3.1.5. Etapa 5: Selección del Número de Clusters	9
3.1.6. Etapa 6: Interpretación y Evaluación	9
3.1.7. Etapa 7: Visualización de Resultados	9
3.1.8. Etapa 8: Interpretación Final	10
4. Resultados	11
5. Conclusiones	18
6. Apéndices	19
6.1. Código Fuente	19
6.2. Descripción de la Base de Datos	22
6.3. Conceptos utilizados	24
6.4. Manual de usuario	25
6.5. Manual técnico	27
6.6. Referencias	29

1. Introducción

El algoritmo de Ward es una técnica de clustering jerárquico aglomerativo que se utiliza ampliamente en el análisis de datos para identificar grupos naturales dentro de un gran conjunto de datos.

Al trabajar con bases de datos grandes, el algoritmo de Ward se destaca por su capacidad para crear clústeres bien definidos y equilibrados, aunque puede ser computacionalmente intenso. Las bibliotecas de Python, como 'scipy', optimizan este proceso, pero la escalabilidad puede requerir consideraciones adicionales como el uso de muestreo o métodos de reducción de dimensionalidad antes de aplicar el clustering.

El algoritmo y la agrupación jerárquica aglomerativa son herramientas poderosas en análisis de datos y pueden aplicarse en una variedad de contextos.

1. **Segmentación de Clientes:** En el marketing, la agrupación jerárquica puede ayudar a identificar grupos de clientes con patrones de compra similares. Esto permite a las empresas diseñar estrategias de marketing personalizadas, mejorar la satisfacción del cliente y optimizar sus recursos.
2. **Análisis Genético:** En bioinformática, la agrupación jerárquica se utiliza para clasificar genes o muestras basadas en patrones de expresión genética. Esto ayuda en la identificación de genes relacionados funcionalmente y en el estudio de enfermedades genéticas.
3. **Organización de la Información:** La agrupación jerárquica puede ser utilizada para organizar grandes colecciones de documentos (como artículos de investigación o noticias) en categorías basadas en similitudes de contenido. Esto facilita la búsqueda y recuperación de información en grandes bases de datos.
4. **Análisis de Redes Sociales:** En las redes sociales, este algoritmo puede ayudar a detectar comunidades o grupos de usuarios con intereses o interacciones similares, lo que puede ser útil para la recomendación de contenidos, publicidad dirigida y estudios de dinámica social.
5. **Reconocimiento de Patrones en Imágenes:** La agrupación jerárquica puede ser aplicada para agrupar píxeles similares en imágenes, lo que es útil en tareas como la segmentación de imágenes, donde se identifican y se separan distintos objetos en una imagen.
6. **Análisis de Consumo de Energía:** En el sector energético, agrupar hogares o industrias según su consumo de energía puede ayudar a identificar patrones y desarrollar estrategias para la eficiencia energética.

Estos ejemplos muestran cómo la agrupación jerárquica aglomerativa se adapta a diversos campos para revelar estructuras ocultas en grandes volúmenes de datos, ayudando a tomar decisiones más informadas y a descubrir relaciones complejas.

2. Descripción del algoritmo

El método de Ward es una técnica de clustering jerárquico diseñada para minimizar la varianza dentro de los clusters.

En cada paso, el método fusiona los pares de clusters que resultan en el menor incremento posible en la suma total de las distancias cuadradas dentro de los clusters, evaluando cómo la combinación de clusters afecta la dispersión interna en comparación con sus centroides originales. Inicia tratando cada punto de datos como un cluster individual y fusiona progresivamente los dos clusters más cercanos según la "distancia de Ward", que mide el aumento en la suma de cuadrados de las distancias hacia el nuevo centroide formado. Este proceso se repite hasta que se forma un solo cluster o se alcanza un número deseado de clusters.

Este método es especialmente efectivo para manejar clusters de tamaños desiguales, manteniendo un equilibrio en el tamaño de los clusters y minimizando la varianza, lo que lo hace adecuado para diversos tipos de análisis de datos.

La técnica de Agrupación Jerárquica es una de las técnicas de agrupación más populares en Machine Learning. La agrupación es la extracción de agrupaciones naturales de objetos de datos similares. Hay un par de ideas generales que ocurren con bastante frecuencia con respecto a la agrupación:

- Los clústeres deben estar presentes de forma natural en los datos.
- El clustering o agrupamiento debe descubrir patrones ocultos en los datos.
- Los puntos de datos dentro del clúster deben ser similares.
- Los puntos de datos en dos grupos diferentes no deben ser similares.

Se basa en el uso de estas técnicas de agrupación para encontrar una jerarquía de agrupaciones, donde esta jerarquía se asemeja a una estructura de árbol, llamada dendrograma.

Existen dos maneras de agrupar los puntos de datos basados en la estructura y el funcionamiento algorítmico:

- Aglomerativo
- Divisivo

2.1. Agrupación Jerárquica Aglomerativa

En un enfoque aglomerativo o enfoque ascendente, cada muestra se trata como un solo clúster y luego se fusionan, o aglomeran, sucesivamente pares de clústeres hasta que todos los clústeres se hayan fusionado en uno solo. En esta técnica, inicialmente cada punto de datos se considera como un clúster individual. En cada iteración, los grupos similares se fusionan con otros grupos hasta que se forma un grupo o grupos K .

El algoritmo básico de aglomeración es sencillo:

- Calcular la matriz de proximidad.
- Dejar que cada punto de datos sea un clúster.
- Repetir: fusionar los dos clústeres más cercanos y actualizar la matriz de proximidad.
- Hasta que solo quede un único clúster.
- La operación clave es el cálculo de la proximidad de dos clústeres.




Figura 1: Ejemplo de Agrupación Jerárquica Aglomerativa

2.2. Agrupación Jerárquica Divisiva

En un agrupamiento divisivo o de arriba hacia abajo, un solo clúster de todas las muestras se divide recursivamente en dos clústeres al menos similares hasta que haya un clúster para cada observación. En la agrupación jerárquica divisiva, consideramos todos los puntos de datos como un único clúster y en cada iteración, separamos los puntos de datos del clúster que no son similares.

Cada punto de datos que se separa se considera como un clúster individual. Al final, nos quedaremos con n grupos. A medida que dividimos los clústeres individuales en n clústeres, se le llama agrupamiento jerárquico divisivo.




Figura 2: Contraste AGLOMERATIVO vs DIVISIVO

2.3. Procedimiento

La operación clave en la agrupación jerárquica es combinar repetidamente los dos clústeres más cercanos en un clúster más grande. Veamos a detalle su funcionamiento:

1. Se calcula la distancia entre cada par de puntos de observación y se almacena en una matriz de distancia.
2. Se coloca cada punto en su propio grupo.
3. Se empieza a fusionar los pares de puntos más cercanos basándose en las distancias de la matriz de distancia, y como resultado, la cantidad de clústeres disminuye en uno.
4. Se recalcula la distancia entre el nuevo clúster y los antiguos y se almacena en una nueva matriz de distancia.
5. Los pasos 2 y 3 se repiten hasta que todos los clústeres se fusionan en uno solo.

2.4. Medidas de Vinculación

Medida de Vinculación de Ward

Incremento mínimo de la suma de cuadrados: En el **método de Ward** utiliza un criterio de incremento mínimo de la **suma de cuadrados** de las distancias dentro del clúster. En cada paso del algoritmo, el método busca fusionar los clústeres que resultan en el menor aumento posible en la suma total de las distancias cuadradas dentro de los clústeres. Esto es equivalente a minimizar el incremento en la varianza total dentro del clúster después de la fusión.

En el **clustering jerárquico**, las medidas de vinculación (o medidas de enlace) son los criterios utilizados para determinar la distancia entre dos conjuntos de observaciones y decidir cuáles clústeres deben fusionarse en cada etapa del proceso. A continuación, se presentan algunas de las medidas de vinculación más comúnmente utilizadas:

1. Enlace Simple (Minimum Linkage):

- **Descripción:** Esta medida de vinculación utiliza la menor distancia entre cualquier par de puntos en dos clústeres. Es decir, la distancia entre dos clústeres se define como la distancia entre los dos puntos más cercanos, uno de cada clúster.
- **Característica:** Tiende a producir clústeres “largos y delgados” y es susceptible a la formación de cadenas.

2. Enlace Completo (Maximum Linkage):

- **Descripción:** A diferencia del enlace simple, el enlace completo utiliza la mayor distancia entre cualquier par de puntos en dos clústeres. La distancia entre dos clústeres se define como la distancia entre los dos puntos más lejanos.
- **Característica:** Tiende a producir clústeres más compactos y bien separados que el enlace simple, pero puede ser sensible a los valores atípicos.

3. Enlace Promedio (Average Linkage):

- **Descripción:** Esta medida calcula la distancia promedio entre todos los pares de puntos en los dos clústeres. Hay dos variantes: el promedio no ponderado (donde se consideran todos los pares igualmente) y el promedio ponderado (que toma en cuenta el tamaño de los clústeres).
- **Característica:** Proporciona un equilibrio entre los enlaces simple y completo, siendo menos susceptible a valores atípicos que el enlace completo.

4. Enlace Centroidal:

- **Descripción:** La distancia entre dos clústeres se define como la distancia entre sus centroides (el promedio de todos los puntos en cada clúster).

- **Característica:** Puede resultar en clústeres más interpretables, pero es susceptible al fenómeno conocido como “inversión”, donde en ciertas circunstancias la distancia entre los clústeres puede disminuir a medida que se agregan más puntos.

5. Método de Ward:

- **Descripción:** Ya descrito anteriormente, este método minimiza el aumento total de la varianza dentro del clúster al fusionar clústeres.
- **Característica:** Tiende a producir clústeres de tamaño más uniforme y es muy útil para datos donde la homogeneidad interna es importante.

Estas medidas de vinculación se utilizan para evaluar cuánto se asemejan o diferencian los grupos de datos en el análisis de clustering jerárquico, y la elección de la medida adecuada puede depender del tipo de datos y del objetivo del análisis.

2.5. Dendrograma

Un dendrograma es un diagrama que ilustra la disposición de los elementos que han sido agrupados mediante clustering jerárquico. Esencialmente, es un árbol que muestra las relaciones entre diferentes grupos o clústeres, representando las similitudes y diferencias entre ellos. Cada rama del dendrograma representa un clúster y la altura de las bifurcaciones refleja la distancia o la diferencia entre los clústeres. Cuanto más alto es el punto donde dos clústeres se unen, mayor es la distancia entre ellos, indicando un menor grado de similitud.

Los dendrogramas son útiles en diversos campos como la biología para analizar similitudes genéticas, en el marketing para entender segmentos de clientes, o en cualquier otra disciplina donde el análisis de agrupaciones pueda proporcionar insights significativos. Permiten visualizar de manera efectiva cómo se forman los grupos a partir de datos y facilitan la decisión sobre el número apropiado de clústeres al observar los puntos de unión de las ramas.




Figura 3: Ejemplo DENDOGRAMA

2.6. Líneas de corte

Las líneas de corte en el método de Ward se determinan según el criterio de minimización de la varianza. En cada paso del proceso de agrupamiento, se calcula la suma de cuadrados dentro del grupo (la suma de las distancias al cuadrado de cada punto respecto al centroide del grupo al que pertenece) y se busca la combinación de clusters que minimice el incremento en esta suma de cuadrados.

Cuando se traza un dendrograma (el gráfico que muestra la jerarquía de agrupamiento), las líneas de corte representan los niveles en los que se pueden formar los clusters. Por ejemplo, si cortas el dendrograma en un nivel más alto, obtendrás menos clusters pero estos serán más grandes y globales, mientras que si cortas en un nivel más bajo, obtendrás más clusters pero estos serán más específicos y pequeños.

En resumen, las líneas de corte en el método de Ward son puntos en un dendrograma donde decides el nivel de granularidad deseado para formar los clusters.




Figura 4: Líneas de corte

En la figura 4 se puede observar que las líneas de corte son las líneas rojas teniendo así 3 líneas de corte.

3. Metodología

3.1. Procedimiento

3.1.1. Etapa 1: Recopilación y preparación de datos

Recopilación de Datos: Esto implica reunir todos los datos relevantes para tu análisis. Asegúrate de tener una comprensión clara de qué variables estás recolectando y cómo se relacionan entre sí. **Limpieza de Datos:** Elimina cualquier dato incompleto, inconsistente o atípico que pueda afectar la calidad de tu análisis. Esto puede incluir la imputación de valores faltantes o la eliminación de registros con datos aberrantes.

3.1.2. Etapa 2: Elección de variables

Selección de Variables: Selecciona las variables que utilizarás para agrupar tus datos. Estas variables deben ser relevantes para tu análisis y tener una medida de distancia adecuada entre ellas. Es importante elegir variables que capturen las características fundamentales de tus datos.

3.1.3. Etapa 3: Cálculo de la matriz de distancias

Calcular Distancias: Utiliza una métrica de distancia apropiada (por ejemplo, distancia euclidiana, distancia de Manhattan) para calcular la distancia entre todas las observaciones en tu conjunto de datos. Esto resultará en una matriz de distancias que representa la similitud o disimilitud entre cada par de observaciones.

3.1.4. Etapa 4: Agrupamiento Jerárquico

Iniciar Agrupamiento: Comienza el proceso de agrupamiento jerárquico, donde cada observación inicialmente se considera un cluster individual. **Agrupamiento por Ward:** Utiliza el método de Ward para calcular la distancia entre los grupos en cada paso del proceso de agrupamiento. El método de Ward minimiza la varianza dentro de cada grupo al fusionar los clusters de manera que la suma de cuadrados de las diferencias entre los puntos y sus respectivos centroides sea mínima.

3.1.5. Etapa 5: Selección del Número de Clusters

Método del Codo: Utiliza el método del codo para determinar el número óptimo de clusters. Este método implica trazar un gráfico de la suma de los cuadrados de las distancias intra-cluster en función del número de clusters y observar el punto donde se produce un $\dot{\text{c}}\text{o}$ do.^o cambio significativo en la pendiente. **Análisis de Dendrograma:** Examina el dendrograma resultante, que muestra la estructura jerárquica de los clusters a medida que se van fusionando. Identifica una división lógica en clusters basada en la altura y la estructura del dendrograma.

3.1.6. Etapa 6: Interpretación y Evaluación

Interpreta los Clusters: Analiza las características de cada cluster para comprender su significado. Esto implica examinar las tendencias y patrones presentes en cada cluster y determinar qué variables contribuyen más a la formación de los clusters. **Evaluación de la Calidad:** Evalúa la calidad de los clusters utilizando métricas como la cohesión dentro de los clusters (por ejemplo, el coeficiente de silueta) y la separación entre los clusters. Cuanto más compactos y separados estén los clusters, mejor será la calidad del agrupamiento.

3.1.7. Etapa 7: Visualización de Resultados

Gráficos: Utiliza gráficos como scatter plots o heatmaps para visualizar los clusters y sus relaciones. Esto te ayudará a entender mejor la estructura de tus datos y a comunicar tus resultados de manera efectiva.

3.1.8. Etapa 8: Interpretación Final

Análisis Final: Realiza un análisis final de los clusters identificados y extrae conclusiones sobre los patrones y relaciones presentes en los datos. Identifica insights relevantes y considera cómo estos clusters pueden ser útiles en tu contexto específico.

4. Resultados

Se pueden visualizar en una ventana del programa algunas de las agrupaciones realizadas por el metodo de WARD, cabe recalcar que solo son algunas de todas las que se realizan.

Esta ventana muestra la agrupación del clúster # con el clúster #, se muestra la distancia que existe entre ambos obtenida por medio de la distancia euclidiana.

Y se muestra el número de clúster restantes por realizar, cada que aparece una nueva agrupación hecha.




Figura 5: Agrupamientos con distancias

Esto agrega tres líneas de corte en las alturas especificadas por `alturaCorte1`, `alturaCorte2` y `alturaCorte3` en el código. Estas alturas son valores arbitrarios que pueden ajustarse según se desee. En este caso, se están utilizando líneas punteadas rojas, azules y verdes respectivamente para visualizar los cortes en diferentes alturas en el dendrograma. Estas líneas de corte ayudan a identificar el número de clústeres a extraer del dendrograma jerárquico.




Figura 6: Dendrograma




Figura 7: Generación de Archivos Excel

El programa genera archivos excel para cada una de las líneas de corte, se encuentran colocadas en distancias de 5, 12 y 20.

Se tiene registro de las instancias y sus respectivos objetos que se encuentran en cada grupo correspondiente a cada línea de corte.

Grupo 1 de la Línea de Corte 5

En cada archivo excel existe un atributo mas al final que corresponde a la linea de corte y al clúster que toma. En este caso es 5, se llama **Cluster 5** el cual indica el indice del cluster que se esta tomando, en el caso del cluster 5, es el grupo 1, por ende toma el cluster 1.

E12																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																					
-----	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--

Figura 8: Grupo 1 de la línea de corte 5

Grupo 1 de la línea de corte 12

En el caso de la línea de corte 12 contiene 2 nuevos atributos al final **Cluster 5** y **Cluster 12**.

Cluster 5 indica el índice del cluster que se esta tomando de dicho cluster para conformar el cluster de la línea de corte 12.

Cluster 12 indica el índice del cluster que se esta tomando en este caso es el grupo 1, por ende toma el valor de 1.

	A	B	C	D	E	F	G	H	I	J
1	STUDENT ID,	1,2,3,4,5,6,7,8,9,10,11,12,13,14,15,16,17,18,19,20,21,22,23,24,25,26,27,28,29,30,	COURSE ID,	GRADE,	Cluster_5,	Cluster_12				
2	STUDENT1,	2,2,3,3,1,2,2,1,1,1,1,2,3,1,2,5,3,2,2,1,1,1,1,3,2,1,2,1,1,1,1,1								
3	STUDENT19,	1,1,2,4,2,2,2,3,1,1,2,2,5,1,2,5,5,3,2,2,1,2,1,1,3,1,3,3,3,1,2,7,1								
4	STUDENT20,	1,2,1,3,2,2,1,2,2,2,3,3,1,2,4,4,2,2,1,2,1,1,1,3,2,2,3,2,3,1,3,7,1								
5	STUDENT23,	2,2,2,3,1,2,1,1,1,1,1,4,2,2,4,3,3,3,1,1,1,2,3,1,2,3,3,3,1,3,4,1								
6	STUDENT26,	2,2,2,3,2,2,1,1,1,2,1,4,3,1,2,4,2,2,2,1,1,1,1,2,1,3,2,1,2,1,3,1,1								
7	STUDENT28,	1,2,1,3,1,2,2,1,1,1,1,4,1,2,3,3,2,2,1,2,1,1,3,1,2,1,2,1,1,1,2,1								
8	STUDENT31,	2,2,2,5,1,1,1,1,1,2,1,1,5,1,2,4,2,2,2,1,1,2,1,2,3,3,3,5,4,1,5,9,1								
9	STUDENT32,	3,2,2,3,1,2,2,1,1,2,1,2,4,1,2,3,2,2,3,1,1,1,1,3,3,2,4,3,1,3,10,1								
10	STUDENT36,	1,2,1,4,2,2,2,3,1,1,1,2,5,1,2,3,2,2,2,1,1,2,1,1,2,1,3,1,1,1,1,2,1								
11	STUDENT40,	2,1,2,3,2,2,1,1,1,2,1,3,1,1,2,4,1,2,1,1,1,1,1,2,2,2,3,2,1,1,1,1,1								
12	STUDENT46,	1,2,2,3,2,2,1,4,1,1,2,3,5,1,2,4,3,2,2,1,1,1,1,2,2,2,1,4,3,1,3,8,1								
13	STUDENT57,	2,2,2,3,2,1,2,1,1,1,1,3,5,1,2,4,4,2,3,1,1,1,2,3,2,3,3,5,4,1,5,12,1								
14	STUDENT62,	1,2,3,3,2,1,2,2,1,2,1,3,4,1,2,3,3,1,2,1,3,2,1,1,3,2,2,4,4,1,5,12,1								
15	STUDENT67,	2,2,2,3,2,2,1,1,1,1,3,2,5,1,2,5,2,2,2,1,1,1,1,3,2,2,3,5,4,2,5,11,1								
16	STUDENT69,	2,1,2,4,1,2,2,1,1,1,2,3,5,3,2,5,1,2,2,1,1,2,1,1,2,2,3,2,4,3,3,5,11,1								
17	STUDENT74,	2,2,2,4,2,2,2,1,1,2,1,3,4,1,2,4,3,1,1,2,1,1,1,2,3,2,3,1,5,3,3,6,12,1								
18	STUDENT79,	2,1,2,4,1,1,2,1,1,1,1,3,4,1,2,4,2,3,3,1,2,1,1,1,3,3,2,2,2,4,4,1,1								
19	STUDENT80,	2,2,2,4,2,2,2,1,1,1,1,3,4,1,2,4,1,2,2,1,3,1,1,1,3,3,2,4,4,4,3,12,1								
20	STUDENT82,	3,2,2,3,1,2,2,1,1,2,1,2,4,1,2,3,2,2,2,1,1,1,1,1,3,3,2,3,5,4,5,3,10,1								
21	STUDENT83,	2,2,2,4,1,2,1,2,1,1,3,1,3,1,2,3,2,2,3,1,1,1,1,1,3,3,2,3,4,3,5,7,10,1								
22	STUDENT92,	2,2,2,5,1,1,1,1,1,2,4,1,5,1,2,3,2,2,2,1,1,1,1,2,3,3,2,5,4,6,6,9,1								
23	STUDENT94,	1,2,2,1,1,2,1,1,1,2,1,2,4,1,2,3,5,2,1,1,1,1,1,3,3,3,2,2,2,6,4,3,1								
24	STUDENT95,	2,2,2,3,2,2,1,1,1,1,3,2,5,1,2,5,2,2,3,1,1,1,1,3,2,2,3,5,4,6,6,11,1								
25	STUDENT106,	1,2,2,4,1,1,2,1,1,1,2,2,4,1,2,4,2,3,2,1,1,2,1,2,2,1,3,1,3,3,7,7,4,1								

Figura 9: Grupo 1 de la línea de corte 12 (parte 1)

25	STUDENT106,	1,2,2,4,1,1,2,1,1,1,2,2,4,1,2,4,2,3,2,1,1,2,1,2,2,1,3,1,3,3,7,7,4,1		
26	STUDENT117,	2,1,2,5,2,2,2,1,1,1,1,5,1,2,4,3,3,3,2,1,1,1,1,3,3,3,1,2,3,8,1,5,1		
27	STUDENT122,	2,1,2,3,1,1,1,1,2,1,1,1,5,3,2,4,5,3,3,1,3,1,2,1,1,1,1,1,1,8,0,6,1		
28	STUDENT126,	1,1,2,5,1,1,2,1,1,3,1,1,5,1,2,3,3,2,3,2,1,1,1,2,3,2,3,1,1,3,9,2,5,1		
29	STUDENT130,	1,1,2,3,1,1,2,1,1,1,1,1,3,1,2,4,4,2,3,2,1,1,2,2,3,2,3,2,2,3,9,3,4,1		
30	STUDENT131,	1,1,2,3,1,1,2,1,1,1,1,2,3,1,2,4,4,2,2,2,1,1,1,2,3,1,3,2,2,3,9,1,4,1		
31	STUDENT141,	2,1,2,3,1,1,2,1,1,2,1,2,2,2,4,3,3,2,1,1,1,1,1,2,1,2,1,3,3,9,5,4,1		
32	STUDENT145,	1,1,1,5,2,2,2,3,1,1,3,1,5,1,2,4,3,1,1,1,1,2,1,3,2,3,1,5,4,9,3,8,1		
33				
34				
35				

Figura 10: Grupo 1 de la línea de corte 12 (parte 2)

Grupo 1 de la Línea de Corte 20

En el caso de la línea de corte 20 contiene 3 nuevos atributos al final **Cluster 5**, **Cluster 12** y **Cluster 20**.

Cluster 5 indica el índice del cluster que se está tomando de dicho cluster para conformar el cluster de la línea de corte 20.

Cluster 12 indica el índice del cluster que se está tomando de dicho cluster para conformar el cluster de la línea de corte 20.

Cluster 20 indica el índice del cluster que se está tomando en este caso es el grupo 1, por ende toma el valor de 1.

	A	B	C	D	E	F	G	H	I	J	K
1	STUDENT ID,	1,2,3,4,5,6,7,8,9,10,11,12,13,14,15,16,17,18,19,20,21,22,23,24,25,26,27,28,29,30,	COURSE ID,	GRADE,	Cluster_5,	Cluster_12,	Cluster_20				
2	STUDENT1	2,2,3,3,1,2,2,1,1,1,1,2,3,1,2,5,3,2,2,1,1,1,1,1,3,2,1,2,1,1,1,1,1,1									
3	STUDENT2	2,2,3,3,1,2,2,1,1,1,2,3,2,1,2,2,2,1,1,1,1,1,3,2,3,2,2,3,1,1,13,2,1									
4	STUDENT3	2,2,2,3,2,2,2,4,2,2,2,2,1,2,1,2,1,2,1,1,1,1,2,2,1,1,2,2,1,1,28,3,1									
5	STUDENT4	1,1,1,3,1,2,1,2,1,2,1,2,5,1,2,1,3,1,2,1,1,1,1,2,3,2,2,1,3,2,1,1,19,2,1									
6	STUDENT5	2,2,1,3,2,2,1,3,1,4,3,3,2,1,2,4,2,1,1,1,1,1,2,1,2,2,2,1,2,2,1,1,38,4,1									
7	STUDENT6	2,2,2,3,2,2,2,2,1,1,3,3,2,1,2,3,1,1,2,1,1,1,1,1,2,1,2,4,1,2,41,4,1									
8	STUDENT7	1,2,2,4,2,2,2,1,1,3,1,3,1,1,2,4,2,2,2,2,1,2,1,1,3,3,3,4,4,1,5,44,4,1									
9	STUDENT8	1,1,2,3,1,1,1,2,2,3,4,3,1,1,4,3,1,2,2,1,1,1,3,1,3,2,2,1,1,1,1,2,49,4,1									
10	STUDENT9	2,1,3,3,2,1,1,1,1,3,2,4,2,1,2,4,1,2,2,1,1,1,1,1,3,2,2,2,4,3,1,5,44,4,1									
11	STUDENT10	2,1,2,3,2,2,1,3,4,2,1,2,3,1,2,3,2,2,2,1,1,2,1,1,2,2,2,2,1,2,1,0,28,3,1									
12	STUDENT11	1,1,1,3,2,2,2,3,2,3,3,4,2,1,3,2,1,1,1,1,1,2,1,1,2,2,2,2,1,1,1,2,50,4,1									
13	STUDENT12	1,1,1,4,1,1,2,4,2,3,5,5,1,1,3,2,3,3,1,3,1,3,2,3,1,3,3,4,3,1,0,54,4,1									
14	STUDENT13	1,1,1,4,2,2,2,1,1,1,3,5,4,2,2,2,3,2,2,1,1,1,1,1,2,2,2,3,4,2,1,0,17,2,1									
15	STUDENT14	2,1,2,5,2,2,2,1,1,1,2,2,2,1,2,3,1,2,1,1,1,2,1,1,3,2,3,3,4,2,1,1,45,4,1									
16	STUDENT15	3,2,2,4,1,1,2,3,4,2,3,1,2,1,4,1,2,2,2,1,1,1,1,1,2,3,2,1,4,4,1,2,31,3,1									
17	STUDENT16	2,2,2,3,2,2,2,1,1,2,4,4,2,1,3,1,2,2,2,2,3,2,1,1,3,2,2,3,2,2,1,2,14,2,1									
18	STUDENT17	1,1,2,5,2,1,2,1,1,1,2,2,4,1,2,3,2,2,2,1,1,2,1,1,3,2,3,3,4,3,1,1,45,4,1									
19	STUDENT18	2,2,2,3,2,2,2,1,1,1,2,2,2,1,2,1,2,2,2,2,1,2,1,1,2,2,2,2,2,1,2,13,2,1									
20	STUDENT19	1,1,2,4,2,2,2,3,1,1,2,2,5,1,2,5,5,3,2,2,1,2,1,1,3,1,3,3,3,1,2,7,1,1									
21	STUDENT20	1,2,1,3,2,2,1,2,2,2,3,3,1,2,4,4,2,2,1,2,1,1,1,3,2,2,3,2,3,1,3,7,1,1									
22	STUDENT21	1,2,2,5,1,2,1,1,4,2,3,3,3,2,2,3,4,2,2,2,1,1,1,2,3,1,2,3,4,4,1,1,33,3,1									
23	STUDENT22	1,2,2,5,2,2,1,1,4,2,2,4,1,2,3,3,2,2,1,1,1,1,1,3,1,3,3,3,3,1,1,33,3,1									
24	STUDENT23	2,2,2,3,1,2,1,1,1,1,1,4,2,2,4,3,3,3,1,1,1,1,2,3,1,2,3,3,3,1,3,4,1,1									
25	STUDENT24	3,2,2,2,1,1,2,5,1,1,1,4,3,1,2,1,3,2,3,1,1,2,1,1,3,2,3,3,3,1,1,25,2,1									

Figura 11: Grupo 1 de la línea de corte 20 (Parte 1)

	A	B	C	D	E	F
25	STUDENT24	3,2,2,2,1,1,2,5,1,1,1,4,3,1,2,1,3,2,3,1,1,2,1,1,3,2,3,3,3,1,1,25,2,1				
26	STUDENT25	2,2,2,3,2,2,2,2,1,1,3,1,3,1,2,4,1,2,2,1,1,1,1,1,2,1,3,2,4,4,1,2,41,4,1				
27	STUDENT26	2,2,2,3,2,2,1,1,1,2,1,4,3,1,2,4,2,2,2,1,1,1,1,2,1,3,2,1,2,1,3,1,1,1				
28	STUDENT27	2,2,2,3,2,1,1,1,1,1,4,4,4,1,2,4,2,3,2,1,1,1,1,3,3,2,2,1,1,1,17,2,1				
29	STUDENT28	1,2,1,3,1,2,2,1,1,1,1,1,4,1,2,3,3,2,2,1,1,2,1,1,3,1,2,1,2,1,1,2,1,1				
30	STUDENT29	3,2,2,3,2,2,1,1,4,2,2,2,4,1,2,1,2,2,2,1,1,1,1,3,2,3,3,5,4,1,3,34,3,1				
31	STUDENT30	2,2,3,4,2,2,2,1,4,2,3,3,2,1,4,1,2,2,2,1,1,1,1,3,2,2,2,4,3,1,5,31,3,1				
32	STUDENT31	2,2,2,5,1,1,1,1,1,2,1,1,5,1,2,4,2,2,2,1,1,1,2,1,2,3,3,3,5,4,1,5,9,1,1				
33	STUDENT32	3,2,2,3,1,2,2,1,1,2,1,2,4,1,2,3,2,2,3,1,1,1,1,3,3,2,3,4,3,1,3,10,1,1				
34	STUDENT33	2,1,2,3,2,2,2,2,1,1,2,2,2,1,2,1,2,2,2,1,1,2,1,2,2,2,1,2,3,1,1,13,2,1				
35	STUDENT34	2,1,2,3,1,2,1,1,1,1,1,2,5,1,2,3,2,1,2,1,1,1,1,1,3,2,2,2,3,1,2,19,2,1				
36	STUDENT35	1,2,1,3,2,2,1,2,1,1,3,3,3,1,2,4,2,1,1,1,1,2,1,1,2,2,3,1,4,1,1,2,40,4,1				
37	STUDENT36	1,2,1,4,2,2,2,3,1,1,1,2,5,1,2,3,2,2,2,1,1,2,1,1,2,1,3,1,1,1,1,2,1,1				
38	STUDENT37	2,2,3,4,1,2,1,3,1,1,1,1,2,2,4,3,1,1,3,1,1,2,2,1,2,1,2,1,4,3,1,2,43,4,1				
39	STUDENT38	2,2,2,3,1,1,1,2,2,3,3,3,1,1,2,3,2,2,2,1,1,1,1,3,2,3,3,5,4,1,1,44,4,1				
40	STUDENT39	2,2,2,5,2,2,2,1,1,1,3,3,1,1,2,4,3,2,2,1,1,1,2,1,2,2,2,4,3,1,2,45,4,1				
41	STUDENT40	2,1,2,3,2,2,1,1,1,2,1,3,1,1,2,4,1,2,1,1,1,1,1,1,2,2,2,3,2,1,1,1,1,1				
42	STUDENT41	1,2,1,3,2,2,2,2,1,1,2,3,1,1,2,5,1,2,2,1,1,1,1,3,1,2,1,2,3,1,1,39,4,1				
43	STUDENT42	3,2,2,3,1,2,2,2,1,2,1,4,2,1,2,2,3,2,2,1,1,2,1,1,3,2,2,3,4,3,1,1,25,2,1				
44	STUDENT43	2,2,2,3,2,1,2,1,4,2,4,2,1,3,1,2,2,1,1,1,1,1,1,2,1,3,1,2,3,1,1,29,3,1				
45	STUDENT44	1,2,2,3,2,2,1,1,1,1,2,3,3,1,2,1,2,2,2,1,1,2,1,1,3,1,3,3,2,1,4,14,2,1				
46	STUDENT45	2,2,3,3,2,2,1,1,1,1,3,3,2,1,2,5,2,2,2,1,1,1,2,1,3,2,2,1,4,3,1,1,42,4,1				
47	STUDENT46	1,2,2,3,2,2,1,4,1,1,2,3,5,1,2,4,3,2,2,1,1,1,1,1,2,2,2,1,4,3,1,3,8,1,1				
48	STUDENT47	2,2,2,3,2,2,1,1,1,1,1,2,3,1,2,5,2,2,2,1,1,1,1,1,2,2,3,1,4,2,1,5,42,4,1				
49	STUDENT48	2,2,2,3,2,2,1,1,1,2,4,3,1,1,5,4,2,2,2,1,1,2,1,1,2,1,3,2,5,3,1,3,57,4,1				
	grupo_1_de_la_línea_de_corte_20					

Figura 12: Grupo 1 de la línea de corte 20 (Parte 2)

	A	B	C	D	E	F
49	STUDENT48	2,2,2,3,2,2,1,1,1,2,4,3,1,1,5,4,2,2,2,1,1,2,1,1,2,1,3,2,5,3,1,3,57,4,1				
50	STUDENT49	1,2,2,3,2,1,1,1,1,2,3,3,3,1,2,2,1,1,2,1,1,1,1,3,2,3,2,2,2,1,1,13,2,1				
51	STUDENT50	1,2,1,4,2,2,2,2,4,1,2,3,2,1,2,4,2,2,2,1,1,1,2,1,2,2,2,1,3,2,1,2,46,4,1				
52	STUDENT51	2,2,2,3,2,2,1,2,2,1,1,1,2,1,2,3,2,2,2,1,1,2,1,1,2,2,2,3,3,1,1,42,4,1				
53	STUDENT52	2,1,3,3,1,1,2,1,1,1,1,2,5,1,2,1,1,2,2,1,1,2,1,1,2,3,3,1,3,3,1,4,19,2,1				
54	STUDENT53	2,1,2,3,1,2,2,2,1,1,1,3,4,1,2,1,3,1,1,1,1,1,1,2,2,2,2,1,4,2,1,1,19,2,1				
55	STUDENT54	2,1,2,3,2,1,2,2,1,1,1,1,5,1,2,1,1,2,2,1,1,2,1,1,2,2,2,2,3,2,1,5,19,2,1				
56	STUDENT55	2,2,2,3,2,2,2,3,4,2,1,4,2,1,4,2,2,1,1,1,1,1,1,2,3,1,3,1,5,3,1,3,32,3,1				
57	STUDENT56	3,2,2,3,1,2,1,4,1,2,1,1,5,3,2,1,1,2,2,1,1,1,3,3,1,3,3,3,5,4,1,3,27,2,1				
58	STUDENT57	2,2,2,3,2,1,2,1,1,1,1,3,5,1,2,4,4,2,3,1,1,1,1,2,3,2,3,3,5,4,1,5,12,1,1				
59	STUDENT58	2,2,2,3,1,1,2,1,1,1,4,2,3,1,3,3,2,3,2,1,1,1,1,3,2,3,1,5,4,1,4,41,4,1				
60	STUDENT59	3,2,2,3,2,2,1,3,1,1,1,3,5,2,2,1,3,2,2,1,1,1,1,3,2,2,2,5,4,1,3,26,2,1				
61	STUDENT60	2,2,2,3,2,1,1,1,1,1,4,4,3,1,2,3,3,2,2,1,1,1,1,3,3,2,2,4,3,1,5,17,2,1				
62	STUDENT61	2,1,2,3,2,2,2,5,2,1,6,1,3,1,2,3,1,2,2,1,1,1,1,1,3,3,1,2,1,1,2,52,4,1				
63	STUDENT62	1,2,3,3,2,1,2,2,1,2,1,3,4,1,2,3,3,1,2,1,3,2,1,1,3,2,2,2,4,4,1,5,12,1,1				
64	STUDENT63	2,2,2,3,2,2,2,1,4,2,2,3,2,1,2,4,3,2,2,1,1,1,1,2,3,3,2,5,4,1,3,46,4,1				
65	STUDENT64	2,2,2,4,2,2,1,2,1,1,1,3,3,1,2,1,1,1,2,1,1,1,3,1,2,2,2,1,3,3,1,5,22,2,1				
66	STUDENT65	2,2,3,5,2,2,2,1,1,1,2,2,2,1,2,1,1,2,2,1,3,1,2,1,3,2,3,1,4,3,1,3,32,2,1				
67	STUDENT66	1,2,2,3,2,2,1,3,1,1,2,4,3,1,2,4,1,1,2,1,3,2,2,1,2,1,2,1,2,2,1,2,40,4,1				
68	STUDENT67	2,2,2,3,2,2,1,1,1,1,3,2,5,1,2,5,2,2,2,1,1,1,1,3,2,2,3,5,4,2,5,11,1,1				
69	STUDENT68	2,2,3,3,1,1,2,3,1,2,3,4,4,2,2,2,2,2,1,1,2,1,1,2,2,1,2,2,3,2,1,15,2,1				
70	STUDENT69	2,1,2,4,1,2,2,1,1,1,2,3,5,3,2,5,1,2,2,1,1,2,1,1,2,2,3,2,4,3,3,5,11,1,1				
71	STUDENT70	2,1,2,4,2,2,1,1,1,1,2,2,2,1,2,3,1,1,2,1,1,1,2,1,3,2,3,1,3,2,3,5,13,2,1				
72	STUDENT71	1,2,2,4,2,1,1,1,1,1,4,3,1,2,4,2,2,2,2,1,1,1,1,1,2,2,3,1,5,4,3,7,57,4,1				
73	STUDENT72	1,1,3,4,2,2,2,1,1,3,1,3,5,1,2,4,2,2,1,1,1,1,1,2,3,3,3,2,2,3,6,21,2,1				
	grupo_1_de_la_línea_de_corte_20					

Figura 13: Grupo 1 de la línea de corte 20 (Parte 3)

	A	B	C	D	E	F
73	STUDENT72	1,1,3,4,2,2,2,1,1,3,1,3,5,1,2,4,2,2,1,1,1,1,1,2,3,3,3,2,2,3,6,21,2,1				
74	STUDENT73	1,2,2,3,2,1,1,1,1,2,1,1,2,1,2,3,2,3,3,1,1,1,1,2,2,3,2,3,3,3,6,42,4,1				
75	STUDENT74	2,2,2,4,2,2,2,1,1,2,1,3,4,1,2,4,3,1,1,2,1,1,1,2,3,2,3,1,5,3,3,6,12,1,1				
76	STUDENT75	1,2,2,4,2,2,2,1,1,1,2,2,3,1,2,1,2,2,2,2,1,1,2,1,3,2,3,2,3,3,7,13,2,1				
77	STUDENT76	1,2,2,4,2,1,2,1,1,3,1,5,4,1,2,2,3,3,1,1,1,1,1,2,2,2,4,1,3,7,21,2,1				
78	STUDENT77	2,2,1,2,2,1,2,2,1,1,5,4,3,1,4,3,2,3,2,1,1,1,3,2,2,1,2,3,2,2,4,4,51,4,1				
79	STUDENT78	1,2,1,2,2,2,1,2,2,2,6,5,2,1,4,2,2,2,2,1,2,3,1,2,2,2,1,1,4,7,51,4,1				
80	STUDENT79	2,1,2,4,1,1,2,1,1,1,1,3,4,1,2,4,2,3,3,1,1,2,1,1,3,3,2,2,2,2,4,4,1,1,1				
81	STUDENT80	2,2,2,4,2,2,2,1,1,1,1,3,4,1,2,4,1,2,2,1,3,1,1,1,3,3,3,2,4,4,4,3,12,1,1				
82	STUDENT81	2,1,2,3,1,2,1,1,2,1,1,1,2,1,2,3,1,1,1,1,3,1,1,1,2,3,1,2,4,2,5,4,23,2,1				
83	STUDENT82	3,2,2,3,1,2,2,1,1,2,1,2,4,1,2,3,2,2,2,1,1,1,1,3,3,2,3,5,4,5,3,10,1,1				
84	STUDENT83	2,2,2,4,1,2,1,2,1,1,3,1,3,1,2,3,2,2,3,1,1,1,1,3,3,2,3,4,3,5,7,10,1,1				
85	STUDENT84	2,2,3,3,2,2,2,3,1,1,4,4,2,1,1,2,1,2,2,1,1,1,3,1,3,2,3,3,1,2,5,7,16,2,1				
86	STUDENT85	3,2,3,3,1,2,1,3,1,2,4,2,5,3,2,1,1,2,2,1,1,1,3,3,3,3,3,5,4,5,7,27,2,1				
87	STUDENT86	1,2,2,5,2,2,2,2,1,1,1,1,5,1,2,1,1,1,1,1,1,1,1,3,2,3,3,4,3,5,4,20,2,1				
88	STUDENT87	2,2,2,4,2,2,2,1,4,2,3,3,2,1,4,1,2,2,2,1,1,1,1,3,2,3,2,5,4,5,5,31,3,1				
89	STUDENT88	2,2,2,3,2,1,2,2,1,1,3,4,2,1,1,1,2,2,2,1,1,1,2,1,2,2,2,1,1,6,6,16,2,1				
90	STUDENT89	1,2,2,4,2,1,1,1,1,1,4,4,1,1,3,2,2,2,2,1,1,1,1,2,3,1,2,3,5,3,6,6,57,4,1				
91	STUDENT90	2,2,2,3,2,2,2,1,1,1,3,5,3,1,2,2,2,2,2,1,1,2,1,1,3,1,3,3,3,2,6,6,14,2,1				
92	STUDENT91	2,1,2,3,2,1,1,1,1,2,3,3,3,1,1,4,2,2,2,2,1,1,1,1,2,3,2,3,4,2,6,6,57,4,1				
93	STUDENT92	2,2,2,5,1,1,1,1,1,2,4,1,5,1,2,3,2,2,2,1,1,1,1,1,2,3,3,2,5,4,6,6,9,1,1				
94	STUDENT93	1,2,2,3,2,2,2,1,1,1,3,4,4,1,3,2,3,2,2,1,1,1,1,1,3,2,3,3,2,2,6,7,14,2,1				
95	STUDENT94	1,2,2,1,1,2,1,1,1,2,1,2,4,1,2,3,5,2,1,1,1,1,1,3,3,3,2,2,6,4,3,1,1				
96	STUDENT95	2,2,2,3,2,2,1,1,1,1,3,2,5,1,2,5,2,2,3,1,1,1,1,3,2,2,3,5,4,6,6,11,1,1				
97	STUDENT96	1,2,3,5,1,1,1,1,2,3,3,4,1,1,2,1,2,2,3,1,1,1,1,3,2,2,1,4,3,7,5,58,4,1				

Figura 14: Grupo 1 de la línea de corte 20 (Parte 4)

	A	B	C	D	E	F
116	STUDENT115	2,1,2,5,1,1,2,4,1,1,1,1,1,2,1,2,2,2,2,1,1,1,2,2,1,2,1,1,8,2,24,2,1				
117	STUDENT116	2,1,2,5,1,2,1,1,1,1,1,1,2,1,2,2,3,3,2,2,3,1,2,2,3,2,3,2,2,8,1,24,2,1				
118	STUDENT117	2,1,2,5,2,2,2,1,1,1,1,1,5,1,2,4,3,3,3,2,1,1,1,1,3,3,3,1,2,3,8,1,5,1,1				
119	STUDENT118	3,1,1,3,2,1,2,1,1,2,4,4,1,1,1,3,2,2,3,2,1,1,2,3,2,1,2,3,8,1,18,2,1				
120	STUDENT119	1,2,2,5,2,1,1,1,4,2,1,2,3,1,4,4,1,2,2,1,1,1,3,1,3,3,2,2,3,8,1,37,3,1				
121	STUDENT120	2,1,2,4,2,1,2,1,1,2,3,3,2,3,2,5,5,2,2,1,1,1,2,2,2,3,1,3,8,2,47,4,1				
122	STUDENT121	2,1,1,3,1,1,1,2,2,3,3,3,2,1,3,4,1,1,1,1,2,2,1,3,3,3,2,2,8,1,49,4,1				
123	STUDENT122	2,1,2,3,1,1,1,1,2,1,1,1,5,3,2,4,5,3,3,1,3,1,2,1,1,1,1,1,1,8,0,6,1,1				
124	STUDENT123	1,2,2,5,2,1,2,1,1,1,3,3,2,1,2,1,2,1,2,1,2,1,3,2,2,1,4,3,8,2,22,2,1				
125	STUDENT124	2,1,3,3,2,2,2,3,1,1,3,2,4,1,1,1,2,2,3,2,1,1,1,1,3,3,2,1,1,8,1,15,2,1				
126	STUDENT125	1,1,2,4,1,1,1,1,1,3,2,3,2,1,4,3,4,2,2,2,1,1,2,2,3,3,2,1,3,3,9,3,35,3,1				
127	STUDENT126	1,1,2,5,1,1,2,1,1,3,1,1,5,1,2,3,3,2,3,2,1,1,1,2,3,2,3,1,1,3,9,2,5,1,1				
128	STUDENT127	1,1,1,4,1,1,1,1,3,2,3,4,6,2,1,4,3,4,2,3,1,1,1,2,1,3,3,3,1,2,2,9,3,56,4,1				
129	STUDENT128	1,1,2,4,2,2,2,1,4,3,3,2,2,1,3,4,2,1,1,2,1,1,1,3,2,2,1,2,2,9,1,36,3,1				
130	STUDENT129	1,1,2,4,2,1,1,1,4,3,3,4,2,1,4,2,2,1,1,2,1,1,1,3,2,2,1,2,2,9,0,36,3,1				
131	STUDENT130	1,1,2,3,1,1,2,1,1,1,1,3,1,2,4,4,2,3,2,1,1,2,2,3,2,3,2,2,3,9,3,4,1,1				
132	STUDENT131	1,1,2,3,1,1,2,1,1,1,1,2,3,1,2,4,4,2,2,2,1,1,1,2,3,1,3,2,2,3,9,1,4,1,1				
133	STUDENT132	1,1,1,5,2,1,2,1,2,2,4,3,1,1,3,2,4,1,3,2,1,1,1,2,3,2,3,1,5,3,9,4,58,4,1				
134	STUDENT133	1,1,1,5,2,1,2,1,1,2,1,2,3,1,2,1,2,3,2,1,1,2,1,3,2,3,1,5,4,9,3,22,2,1				
135	STUDENT134	1,1,2,5,2,2,1,1,1,1,1,1,1,2,3,3,1,2,2,1,1,1,1,3,3,3,2,5,3,9,3,45,4,1				
136	STUDENT135	1,1,2,4,2,1,2,1,2,3,1,1,2,1,4,3,2,2,2,2,1,1,1,2,1,2,1,2,3,9,1,35,3,1				
137	STUDENT136	2,1,2,3,1,1,2,1,4,2,3,3,1,1,2,1,2,3,2,1,3,1,1,1,3,3,2,1,3,2,9,2,30,3,1				
138	STUDENT137	1,1,2,3,1,1,1,1,2,3,3,3,3,1,3,4,2,2,2,2,1,1,3,1,3,2,2,1,2,2,9,0,49,4,1				
139	STUDENT138	1,1,1,5,2,1,2,1,1,1,2,2,2,1,2,1,2,2,2,1,1,1,1,3,1,3,1,2,4,9,2,13,2,1				
140	STUDENT139	1,1,2,4,1,1,1,5,2,3,3,1,1,2,4,5,2,2,3,2,3,1,2,1,3,2,3,1,1,3,9,0,53,4,1				
141	STUDENT140	1,1,2,4,1,2,1,2,3,3,3,1,5,4,1,1,2,2,1,2,2,1,2,3,2,1,1,2,9,0,49,4,1				
142	STUDENT141	2,1,2,3,1,1,2,1,1,2,1,2,2,2,4,3,3,2,1,1,1,1,1,2,1,2,1,3,3,9,5,4,1,1				
143	STUDENT142	1,1,2,4,2,2,2,1,4,2,1,1,5,1,2,1,3,2,2,2,1,2,1,1,3,2,2,1,5,3,9,5,34,3,1				
144	STUDENT143	1,1,1,4,2,2,2,1,1,3,4,4,1,2,4,2,2,2,1,1,1,1,3,3,2,1,4,3,9,1,17,2,1				
145	STUDENT144	2,1,2,4,1,1,1,5,2,3,4,4,1,1,3,3,2,2,1,1,1,2,1,2,1,2,1,5,3,9,4,55,4,1				
146	STUDENT145	1,1,1,5,2,2,2,3,1,1,3,1,5,1,2,4,3,1,1,1,1,2,1,3,2,3,1,5,4,9,3,8,1,1				

Figura 15: Grupo 1 de la línea de corte 20 (Parte 5)

5. Conclusiones

Implementar el método de Ward en Python para analizar bases de datos grandes ofrece una oportunidad valiosa para descubrir clústeres cohesivos y bien diferenciados, aunque enfrenta desafíos significativos en términos de escalabilidad y eficiencia computacional. Aunque es intensivo en cuanto a cálculos y uso de memoria, lo que puede limitar su uso en aplicaciones de tiempo real o bases de datos extremadamente grandes, sigue siendo una herramienta poderosa para análisis detallados en diversos campos, donde la calidad del agrupamiento es más importante que la velocidad de procesamiento.

En el desarrollo de esta practica se encontraron dificultades y complicaciones, por lo que resulto mas interesante la implementación del metodo de Ward en python utilizando una base de datos tan grande

Detalles importantes que podemos resaltar de esta práctica:

- **Escalabilidad y eficiencia computacional**
- **Gestión de recursos**
- **Tiempo de ejecución**
- **Aplicación en diversos campos**
- **Mejora constante del metodo y de su visualización**
- **Toma de desiciones**

6. Apéndices

6.1. Código Fuente

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from scipy.cluster.hierarchy import dendrogram
5 from scipy.cluster.hierarchy import fcluster
6 import os
7
8
9 import customtkinter as ctk
10 from tkinter import filedialog, messagebox
11
12 # Creacion de la ventana principal
13 root = ctk.CTk()
14 root.title("Clasificación Jerárquica")
15 root.geometry("800x600") # Define un tamaño inicial para la ventana
16
17 # Variable para guardar la ruta del archivo de entrenamiento
18 entrenamiento_archivo = ctk.StringVar()
19
20 # Funciones para cargar los archivos y procesar datos
21 def cargar_archivo_entrenamiento():
22     archivo = filedialog.askopenfilename(filetypes=[('Archivos CSV', '*.csv')])
23     entrenamiento_archivo.set(archivo)
24
25 def mostrar_resultados(resultados_ward):
26     # limpia el frame
27     for widget in scrollable_frame1.winfo_children():
28         widget.destroy()
29
30     # Ahora, iteramos sobre los resultados del agrupamiento y creamos un label por cada uno
31     for paso in resultados_ward:
32         texto = f"Agrupamiento de clusters {paso[0]} y {paso[1]} con distancia de {paso[2]:.2f}. Clusters restantes: {paso[3]}"
33         label = ctk.CTkLabel(scrollable_frame1, text=texto) # Añadir directamente al scrollable_frame1
34         label.pack(pady=2, padx=10, fill='x')
35
36
37     # Crear una nueva figura de matplotlib
38     plt.figure(figsize=(10, 7))
39     # Dibujar el dendrograma
40     dendrogram(resultados_ward)
41     plt.title("Dendrograma de Agrupamiento Jerárquico")
42     plt.xlabel("Índice de la Muestra")
43     plt.ylabel("Distancia de Ward")
44
45     # Agregar líneas de corte
46     altura_corte1 = 5
47     altura_corte2 = 12
48     altura_corte3 = 20
49     plt.axhline(y=altura_corte1, color='r', linestyle='--')
50     plt.axhline(y=altura_corte2, color='b', linestyle='--')
51     plt.axhline(y=altura_corte3, color='g', linestyle='--')
52
53     # Mostrar el gráfico
54     plt.show()
55
56 def guardar_clusters(resultados_ward, alturas, archivo_base):
57
58     datos = pd.DataFrame({'índice': range(1, len(resultados_ward) + 2)})
59
60     cluster_labels = {}
61     for altura in alturas:
62         # Obtener los clusters a la altura especificada
63         clusters = fcluster(resultados_ward, altura, criterion='distance')

```

```

65     cluster_labels[altura] = clusters
66
67     # Guardar un archivo para cada altura con los clusters correspondientes
68     for altura in alturas:
69         archivo_nombre = f'{archivo_base}cluster_hasta{altura}.csv'
70         # Seleccionar solo la columna de clusters de la altura actual
71         datos_temp = pd.DataFrame({
72             'indice': datos['indice'],
73             f'clusters_{altura}': cluster_labels[altura]
74         })
75         datos_temp.to_csv(archivo_nombre, index=False)
76         print(f'Archivo guardado: {archivo_nombre}')
77
78
79 def agrupamiento_ward():
80     if entrenamiento_archivo.get():
81         datos = pd.read_csv(entrenamiento_archivo.get())
82         datos_procesados = preparar_datos(datos)
83         X = datos_procesados.values.astype(float) # Intentar convertir a float
84         resultados_ward = calcular_ward(X)
85         mostrar_resultados(resultados_ward)
86     else:
87         messagebox.showerror("Error", "Por favor, seleccione un archivo primero.")
88
89
90 def preparar_datos(datos):
91     # Eliminar columnas no numéricas y aadir las transformadas
92     datos_numericos = datos.drop(columns=['STUDENT ID'])
93     datos_procesados = pd.concat([datos_numericos], axis=1)
94
95     return datos_procesados
96
97
98
99 def calcular_ward(X):
100     # Calcula la matriz de distancias Euclidianas entre cada par de muestras en X
101     distancias = np.sqrt((X[:, np.newaxis, :] - X[np.newaxis, :, :]) ** 2).sum(axis=2))
102
103     # Establece la diagonal de la matriz de distancias a infinito para evitar considerar la
104     # distancia de una muestra consigo misma
105     np.fill_diagonal(distancias, np.inf)
106
107     # N mero de muestras en el conjunto de datos
108     num_muestras = X.shape[0]
109
110     # Inicializa una lista de ndices para los cl steres activos, cada muestra comienza como
111     # su propio cl ster
112     cl_steres_activos = list(range(num_muestras))
113
114     # Lista para almacenar los resultados de las fusiones de cl steres
115     matriz_enlace = []
116
117     # ndice que se asignar a los nuevos cl steres formados por fusiones
118     nuevo_indice = num_muestras
119
120     # Array para llevar la cuenta del n mero de elementos en cada cl ster, inicialmente 1
121     # por cada muestra
122     tama os_clusters = np.ones(num_muestras)
123
124     # Contin a fusionando cl steres hasta que solo queda uno
125     while len(cl_steres_activos) > 1:
126         # Encuentra el par de cl steres con la menor distancia entre ellos
127         i, j = np.unravel_index(np.argmin(distancias), distancias.shape)
128         dist_min = distancias[i, j]
129
130         # A ade el resultado de esta fusi n a la matriz de enlace
131         matriz_enlace.append([cl_steres_activos[i], cl_steres_activos[j], dist_min, len(
132             cl_steres_activos) - 1])
133
134         # Actualiza el tama o del cl ster resultante de la fusi n de i y j

```

```

131     nuevo_tamano = tamaños_clusters[i] + tamaños_clusters[j]
132     tamaños_clusters[i] = nuevo_tamano
133
134     # Actualiza las distancias del nuevo cluster con todos los otros clusters
135     for k in range(len(distancias)):
136         if k != i and k != j:
137             dist_ik = distancias[k, i]
138             dist_jk = distancias[k, j]
139             # Aplica la fórmula de Ward para calcular la nueva distancia entre el
140             # cluster fusionado y el cluster k
141             distancias[k, i] = distancias[i, k] = np.sqrt(
142                 ((tamaños_clusters[i] + tamaños_clusters[k]) * dist_ik**2 +
143                  (tamaños_clusters[j] + tamaños_clusters[k]) * dist_jk**2 -
144                  tamaños_clusters[k] * dist_min**2) /
145                 (tamaños_clusters[i] + tamaños_clusters[j] + tamaños_clusters[k])
146             )
147
148     # Elimina el cluster j de la matriz de distancias y del array de tamaños de
149     # clusters
150     distancias = np.delete(distancias, j, axis=0)
151     distancias = np.delete(distancias, j, axis=1)
152     tamaños_clusters = np.delete(tamaños_clusters, j)
153
154     # Actualiza los índices de clusters activos, asignando el nuevo índice al cluster
155     # fusionado
156     clusters_activos[i] = nuevo_indice
157     clusters_activos.pop(j)
158
159     # Incrementa el índice para la próxima fusión
160     nuevo_indice += 1
161
162     guardar_clusters(matriz_enlace, [5, 12, 20], r'C:\Users\criss\OneDrive\Documentos\UNI\
163     mineria\archivo_base')
164
165
166     # Devuelve la matriz de enlace que describe el orden y las distancias de las fusiones de
167     # clusters
168     return np.array(matriz_enlace)
169
170 # Widgets de la interfaz
171 title_label = ctk.CTkLabel(root, text="Clasificación Jerárquica", font=ctk.CTkFont(size=20,
172     weight="bold"))
173 title_label.pack(pady=20)
174
175 entrenamiento_frame = ctk.CTkFrame(root)
176 entrenamiento_frame.pack(pady=10, padx=20)
177
178 entrenamiento_titulo_label = ctk.CTkLabel(entrenamiento_frame, text="Ingreso archivo", font=
179     ctk.CTkFont(size=15, weight="bold"))
180 entrenamiento_titulo_label.pack(side="left", padx=10)
181
182 entrenamiento_archivo_entry = ctk.CTkEntry(entrenamiento_frame, textvariable=
183     entrenamiento_archivo, state="readonly", width=300)
184 entrenamiento_archivo_entry.pack(side="left", padx=10)
185
186 entrenamiento_archivo_button = ctk.CTkButton(entrenamiento_frame, text="Seleccionar archivo",
187     command=cargar_archivo_entrenamiento)
188 entrenamiento_archivo_button.pack(pady=20, padx=50, fill='x', expand=True)
189
190 entrenamiento_button = ctk.CTkButton(root, text="Agrupar", command=agrupamiento_ward)
191 entrenamiento_button.pack(pady=20, padx=20)
192
193 scrollable_frame1 = ctk.CTkScrollableFrame(root, width=310, height=300)
194 scrollable_frame1.pack(pady=20, fill="both", expand=True)
195
196 # Iniciar el bucle de eventos principal
197 root.mainloop()

```

6.2. Descripción de la Base de Datos

Característica	Descripción
Multivariante	Sí
Área temática	Ciencias Sociales
Tareas asociadas	Clasificación
Tipo de característica	Entero
# Instancias	145
# Características	31

Cuadro 1: Detalles de las Variables - Parte 1

Variable Name	Role	Type	Demographic
Student Age	Feature	Categorical	Age
Sex	Feature	Binary	Sex
Graduated high-school type	Feature	Categorical	Education Level
Scholarship type	Feature	Categorical	
Additional work	Feature	Binary	
Regular artistic or sports activity	Feature	Binary	
Do you have a partner	Feature	Binary	Marital Status
Total salary if available	Feature	Categorical	Income
Transportation to the university	Feature	Categorical	
Accommodation type in Cyprus	Feature	Categorical	
Mother's education	Feature	Categorical	Education Level
Father's education	Feature	Categorical	Education Level
Number of siblings	Feature	Integer	
Parental status	Feature	Categorical	Marital Status
Mother's occupation	Feature	Categorical	Occupation
Father's occupation	Feature	Categorical	Occupation
Weekly study hours	Feature	Categorical	
Reading frequency (non-scientific)	Feature	Categorical	
Reading frequency (scientific)	Feature	Categorical	
Attendance to seminars/conferences	Feature	Binary	
Impact of projects/activities	Feature	Categorical	
Attendance to classes	Feature	Categorical	
Preparation to midterm exams 1	Feature	Categorical	
Preparation to midterm exams 2	Feature	Categorical	
Taking notes in classes	Feature	Categorical	
Listening in classes	Feature	Categorical	
Discussion improves interest/success	Feature	Categorical	
Flip-classroom	Feature	Categorical	
Cumulative GPA last semester	Feature	Categorical	
Expected Cumulative GPA	Feature	Categorical	
Course ID	Feature	Integer	
OUTPUT Grade	Target	Categorical	
Student ID	ID	Categorical	

Cuadro 2: Detalles de las Variables - Parte 2

Description	Missing Values
1: 18-21, 2: 22-25, 3: above 26	no
1: female, 2: male	no
1: private, 2: state, 3: other	no
1: None, 2: 25 %, 3: 50 %, 4: 75 %, 5: Full	no
1: Yes, 2: No	no
1: Yes, 2: No	no
1: Yes, 2: No	no
1: USD 135-200, 2: USD 201-270, 3: USD 271-340, 4: USD 341-410, 5: above 410	no
1: Bus, 2: Private car/taxi, 3: bicycle, 4: Other	no
1: rental, 2: dormitory, 3: with family, 4: Other	no
1: primary school, 2: secondary school, 3: high school, 4: university, 5: MSc., 6: Ph.D.	no
1: primary school, 2: secondary school, 3: high school, 4: university, 5: MSc., 6: Ph.D.	no
1: 1, 2: 2, 3: 3, 4: 4, 5: 5 or above	no
1: married, 2: divorced, 3: died - one or both	no
1: retired, 2: housewife, 3: government officer, 4: private sector employee, 5: self-employed, 6: other	no
1: retired, 2: housewife, 3: government officer, 4: private sector employee, 5: self-employed, 6: other	no
1: None, 2: ≤5 hours, 3: 6-10 hours, 4: 11-20 hours, 5: more than 20 hours	no
1: None, 2: Sometimes, 3: Often	no
1: None, 2: Sometimes, 3: Often	no
1: Yes, 2: No	no
1: positive, 2: negative, 3: neutral	no
1: always, 2: sometimes, 3: never	no
1: alone, 2: with friends, 3: not applicable	no
1: closest date to the exam, 2: regularly during the semester, 3: never	no
1: never, 2: sometimes, 3: always	no
1: never, 2: sometimes, 3: always	no
1: never, 2: sometimes, 3: always	no
1: not useful, 2: useful, 3: not applicable	no
1: ≤2.00, 2: 2.00-2.49, 3: 2.50-2.99, 4: 3.00-3.49, 5: above 3.49	no
1: ≤2.00, 2: 2.00-2.49, 3: 2.50-2.99, 4: 3.00-3.49, 5: above 3.49	no
	no
0: Fail, 1: DD, 2: DC, 3: CC, 4: CB, 5: BB, 6: BA, 7: AA	no
	no

6.3. Conceptos utilizados

Distancia euclidiana:

La distancia euclidiana es uno de los métodos más comunes y fundamentales para medir la distancia entre puntos en un espacio de características. Se define como la longitud de la línea segmentaria entre dos puntos en un espacio euclidiano (es decir, geometría ordinaria de varias dimensiones). La fórmula matemática para calcular la distancia euclidiana entre dos puntos p y q en un espacio de n -dimensiones es:

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_n - q_n)^2} \quad (1)$$

donde p_i y q_i son las coordenadas de los puntos p y q respectivamente. Esta medida es intuitiva y fácil de entender, ya que se basa en el teorema de Pitágoras.

Dendograma: Un dendograma es un tipo de diagrama de árbol utilizado en análisis de datos para representar las relaciones de agrupamiento entre diferentes objetos, como variables en un conjunto de datos o grupos de individuos. Se utiliza comúnmente en técnicas de clustering (agrupamiento), donde se intenta identificar grupos naturales o patrones en los datos.

Varianza: El método de Ward utiliza la varianza como medida de la disimilitud entre clusters. Busca minimizar la suma de cuadrados dentro de los clusters, lo que significa que trata de hacer que los clusters sean lo más compactos y homogéneos posible.

Fórmula de incremento en la Suma de Cuadrados: Cuando se considera fusionar dos clusters en el método de Ward, se calcula el aumento en la suma total de cuadrados dentro de los clusters.

$$\Delta SS = \frac{n_i \cdot n_j}{n_i + n_j} \cdot \|\bar{x}_i - \bar{x}_j\|^2 \quad (2)$$

Combinación de Centroides: Al fusionar dos clusters, también se recalcula el centroide del nuevo cluster combinado, usando la fórmula:

$$\bar{x}_{new} = \frac{n_i \cdot \bar{x}_i + n_j \cdot \bar{x}_j}{n_i + n_j} \quad (3)$$

Este nuevo centroide es un promedio ponderado de los centroides de los clusters originales, ponderado por los tamaños de los clusters.

Granularidad: El concepto granularidad representa el nivel de detalle al que se desea almacenar y presentar la información. Por ejemplo, no es lo mismo contar el tiempo por horas (grano fino) que por semanas (grano grueso).

6.4. Manual de usuario

Descripción General

Esta aplicación permite a los usuarios realizar una clasificación jerárquica de datos y visualizar los resultados mediante un dendrograma. Es útil para análisis de clustering en conjuntos de datos.

Requisitos del Sistema

- Python 3.x instalado.
- Bibliotecas requeridas: pandas, numpy, matplotlib, scipy, customtkinter.

Instalación

- Asegúrese de tener Python instalado en su sistema.
- Instale las bibliotecas necesarias usando pip:

```
pip install pandas numpy matplotlib scipy customtkinter
```

Figura 16: Bibliotecas

Instrucciones de Uso

1. Inicio del Programa:

- Ejecuta el código, en la parte superior de tu entorno de trabajo.




Figura 17: Ejecutar

2. Cargar un Archivo de Datos:

- Haga clic en el botón Seleccionar archivo.




Figura 18: Bibliotecas

- Navegue hasta el archivo .csv que desea analizar y selecciónelo.




Figura 19: Bibliotecas

- El archivo debe estar en formato CSV y contener datos numéricos.

3. Ejecutar la Clasificación Jerárquica:

- Una vez cargado el archivo, presione el botón Agrupar. aplicación procesará los datos y mostrará los resultados en una nueva ventana.




Figura 20: Bibliotecas

4. Visualización de Resultados:

- En la nueva ventana, se mostrarán los detalles de la agrupación de clústeres.




Figura 21: Agrupación de clústeres

- Para cada fusión de clústeres, se indica qué clústeres se han combinado, la distancia a la que se combinaron y el número de clústeres restantes.

5. Visualización del Dendrograma:

- El dendrograma muestra cómo los clústeres están relacionados entre sí y las distancias de agrupamiento.




Figura 22: Dendrograma

6. Guardar los Clústeres:

- Los clústeres generados se guardan automáticamente en archivos .csv en la ubicación especificada en el código.

6.5. Manual técnico

Parte 1: Instalar Python

Para instalar Python en tu sistema Windows, sigue estos pasos:

1. **Descargar el instalador de Python:** Ve al sitio web oficial de Python (<https://www.python.org/downloads/>) y descarga el instalador adecuado para tu sistema Windows. Se recomienda descargar la versión más reciente de Python, que esté marcada como estable.
2. **Ejecutar el instalador:** Una vez que se haya completado la descarga, debe hacer doble clic en el archivo descargado para ejecutar el instalador de Python. Asegúrate de marcar la opción Agregar Python X.X a PATH durante la instalación para que Python se agregue automáticamente a la variable de entorno PATH del sistema.
3. **Completar la instalación:** Sigue las instrucciones en pantalla para completar la instalación de Python. Asegúrate de marcar la opción para instalar pip, que es un administrador de paquetes de Python utilizado para instalar y administrar bibliotecas y paquetes de terceros.
4. **Verificar la instalación:** Una vez que la instalación haya finalizado, abre una ventana de comandos (CMD) y escribe el siguiente comando para verificar que Python se haya instalado correctamente:

```
python --version
```

Deberías ver la versión de Python instalada en tu sistema.

5. **Instalar un entorno de desarrollo (opcional):** Si planeas desarrollar en Python, considera instalar un entorno de desarrollo integrado (IDE) como Spyder, PyCharm o Visual Studio Code. Estos IDE proporcionan características adicionales, como resaltado de sintaxis, depuración de código y administración de proyectos.

Adicionalmente, para una correcta ejecución es necesario importar las siguientes librerías, como Pandas para el manejo de datos, NumPy para operaciones matemáticas, customtkinter para la creación de la interfaz gráfica de usuario y scipy para la implementación del Dendrograma. Es importante mencionar que los comandos proporcionados a continuación tienen que ser ejecutados desde la terminal (Cmd) Instalar "pandas", utilizaremos

```
pip install pandas
```

Instalar numpy

```
pip install numpy
```

Instalar customtkinter

```
pip install customtkinter
```

Instalar scipy

```
pip install scipy
```

Parte 2: Anaconda

El programa que se utilizará es muy sencillo y práctico tanto para su uso e instalación, es un código abierto multiplataforma entorno de desarrollo integrado (IDE) para la programación científica en el lenguaje python. Spyder se integra con una serie de paquetes prominentes en la pila científica de Python, que incluyen NumPy, SciPy, Matplotlib, pandas, IPython, Simpatío y Citón, así como otro software de código abierto.

Instalación en Windows

Para instalar Spyder con Anaconda en Windows, siga estos pasos:

1. Descargue el instalador de Anaconda desde el sitio web oficial: <https://www.anaconda.com/products/distribution> guardelo en una carpeta conocida para ejecutar una vez terminada la descarga.
2. Ejecute el instalador descargado desde la carpeta en la que lo guardo y siga las instrucciones en pantalla para completar la instalación de Anaconda.
3. Una vez que Anaconda esté instalado, abra Anaconda Navigator desde el menú de inicio.
4. En Anaconda Navigator, haga clic en el botón 'Instalar' junto al paquete de Spyder.
5. Espere a que se complete la instalación y luego ejecute Spyder desde Anaconda Navigator o desde el menú de inicio.

Parte 3: Spyder

1. **Explorar la interfaz de usuario:** Al abrir Spyder, verás una interfaz de usuario dividida en diferentes paneles, como el editor de código, el explorador de variables y la consola IPython. Familiarízate con estos paneles, ya que serán útiles para tu trabajo con Python.
2. **Escribir y ejecutar código:** Utiliza el editor de código para escribir tu código Python. Selecciona el código que deseas ejecutar y haz clic en el botón 'Ejecutar' en la barra de herramientas o presiona 'Ctrl + Enter'. Verás la salida de tu código en la consola IPython.
3. **Explorar características adicionales:** Spyder ofrece muchas características adicionales, como depuración de código, autocompletado de código y ayuda integrada. Explora estas características para mejorar tu productividad en el desarrollo de Python.

6.6. Referencias

A. B. Dongo Román, *Descripción metodológica del análisis Clúster utilizando el algoritmo de Ward*, 2017.

D. Pascual, F. Pla, & S. Sánchez, *Algoritmos de agrupamiento*, Método Informáticos Avanzados, pp. 164-174, 2007.

emphUC Irvine Machine Learning Repository, UC Irvine Machine Learning Repository, 2019, <https://archive.ics.uci.edu/dataset/856/higher+education+students+performance+evaluation>